Simonelli on Assertibility of pure LLMs

Injin Woo & Donggeon Kim

발표 자료 (EN / KO)

2nd Philosophical Interchange between Sungkyunkwan and Nagoya University

Nagoya University, Japan

25 Oct 2026

논제: 공통 충분조건의 성취별 적용

출발점

시모넬리는 LLM의 개념 이해의 충분조건으로 **추론적 숙달**을 제시한다.

우리의 논제

그 조건을 LLM에 실제로 적용하려면 **성취별 성립 조건**을 구별해야 하며, 실험 결과상 **한 성취의 성공이 다른 성취의 숙달을 보장하지 않는다.**

논제: 공통 충분조건의 성취별 적용

출발점

시모넬리는 LLM의 개념 이해의 충분조건으로 **추론적 숙달**을 제시한다.

우리의 논제

그 조건을 LLM에 실제로 적용하려면 **성취별 성립 조건**을 구별해야 하며, 실험 결과상 **한 성취의 성공이 다른 성취의 숙달을 보장하지 않는다.**

두 단계의 논증

첫째: 현재 숙달의 귀속

적절한 이유 반응에는 **이유가 영향을 미치는 범위의 구별**이 필요하다. 기존 성공과 추가 사건의 처리가 분리된다면, 공통 기준도 성취별로 적용해야 한다.

둘째: 추가 숙달의 학습

기존 성취의 개선이 추가 능력의 획득을 지지하는 정도는 **그 능력을 형성할 학습상의 연결**에 달려 있다.

두 단계의 논증

첫째: 현재 숙달의 귀속

적절한 이유 반응에는 **이유가 영향을 미치는 범위의 구별**이 필요하다. 기존 성공과 추가 사건의 처리가 분리된다면, 공통 기준도 성취별로 적용해야 한다.

둘째: 추가 숙달의 학습

기존 성취의 개선이 추가 능력의 획득을 지지하는 정도는 **그 능력을 형성할 학습상의 연결**에 달려 있다.

시모넬리의 논증

(GSI) 추론적 역할의 숙달은 **모든 개념**의 보유에 충분하다.

(학습 전제) 언어 자료에 대한 훈련은 원리적으로 그러한 숙달에 충분하다.

(결론) 따라서 텍스트만으로 훈련한 LLM도 원리적으로 모든 개념을 보유할 수 있다.

시모넬리의 논증

(GSI) 추론적 역할의 숙달은 **모든 개념**의 보유에 충분하다.

(학습 전제) 언어 자료에 대한 훈련은 원리적으로 그러한 숙달에 충분하다.

(결론) 따라서 텍스트만으로 훈련한 LLM도 원리적으로 모든 개념을 보유할 수 있다.

시모넬리의 논증

(GSI) 추론적 역할의 숙달은 **모든 개념**의 보유에 충분하다.

(학습 전제) 언어 자료에 대한 훈련은 원리적으로 그러한 숙달에 충분하다.

(결론) 따라서 텍스트만으로 훈련한 LLM도 원리적으로 모든 개념을 보유할 수 있다.

메리의 방: 경험 없는 개념 이해

시모넬리가 받아들이는 설정

메리는 색을 경험하지 않았지만, 색 개념을 분절하는 추론 관계를 모두 파악한다. 빨강과 다른 색의 관계, 사물이 빨간 조건, 다른 사람이 빨강을 보게 되는 조건도 안다.

1. 개념 이해가 관련 추론 관계의 숙달에 달려 있다면,
2. 그 관계를 숙달한 메리에게 색 경험이 없다는 사실은
3. **색 개념의 이해를 배제하는 근거가 되지 않는다.**

Simonelli 2026, 7–8쪽.

메리의 방: 경험 없는 개념 이해

시모넬리가 받아들이는 설정

메리는 색을 경험하지 않았지만, 색 개념을 분절하는 추론 관계를 모두 파악한다. 빨강과 다른 색의 관계, 사물이 빨간 조건, 다른 사람이 빨강을 보게 되는 조건도 안다.

1. 개념 이해가 관련 추론 관계의 숙달에 달려 있다면,
2. 그 관계를 숙달한 메리에게 색 경험이 없다는 사실은
3. **색 개념의 이해를 배제하는 근거가 되지 않는다.**

Simonelli 2026, 7–8쪽.

메리의 방

방 안

메리는 색에 관한 관련 추론 관계를 충분히 숙달했지만 빨강을 직접 보지 못했다.

방 밖

처음 빨강을 본다. 새 경험을 얻는다는 사실이 곧 새 개념을 얻는다는 뜻인가?

시모넬리의 방어

이미 충분히 숙달했다면, 경험의 부재만으로 개념 보유를 부정할 수 없다.
메리는 빨강 경험 자체는 없지만, '빨강' 과 '빨강을 봄' 의 내용을 분절하는 추론 관계를 모두 파악한다. 개념적 내용이 모두 언어적으로 명료화될 수 있다면, 경험의 부재 때문에 메리가 반드시 놓치는 개념적 내용은 없다.

메리의 방

방 안

메리는 색에 관한 관련 추론 관계를 충분히 숙달했지만 빨강을 직접 보지 못했다.

방 밖

처음 빨강을 본다. 새 경험을 얻는다는 사실이 곧 새 개념을 얻는다는 뜻인가?

시모넬리의 방어

이미 충분히 숙달했다면, 경험의 부재만으로 개념 보유를 부정할 수 없다.
메리는 빨강 경험 자체는 없지만, '빨강' 과 '빨강을 봄' 의 내용을 분절하는 추론 관계를 모두 파악한다. 개념적 내용이 모두 언어적으로 명료화될 수 있다면, 경험의 부재 때문에 메리가 반드시 놓치는 개념적 내용은 없다.

메리의 기여와 학습의 문제

긍정적 기여

경험 없는 이해를 배제하는 반론을 약화한다. 언어 학습의 전망에서 장애 하나가 제거된다.

획득에 관한 추가 물음

메리의 사례에서는 이미 숙달이 주어져 있다. 반면, LLM에서는 어떤 언어 훈련이 그 숙달을 **형성할 수 있는지**를 뒷받침해야 한다.

숙달을 가정한 사례는 실제 모델의 성공과 실패가 **더 넓은 능력의 획득**을 보여주는지를 확정하지 못한다.

메리의 기여와 학습의 문제

긍정적 기여

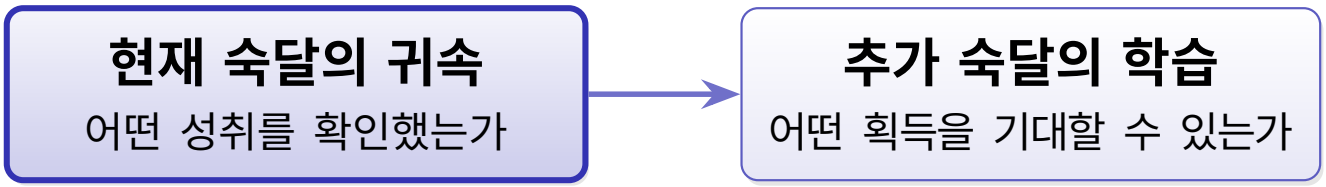
경험 없는 이해를 배제하는 반론을 약화한다. 언어 학습의 전망에서 장애 하나가 제거된다.

획득에 관한 추가 물음

메리의 사례에서는 이미 숙달이 주어져 있다. 반면, LLM에서는 어떤 언어 훈련이 그 숙달을 **형성할 수 있는지**를 뒷받침해야 한다.

숙달을 가정한 사례는 실제 모델의 성공과 실패가 **더 넓은 능력의 획득**을 보여주는지를 확정하지 못한다.

논증 1: 성취별 숙달을 판별해야 한다

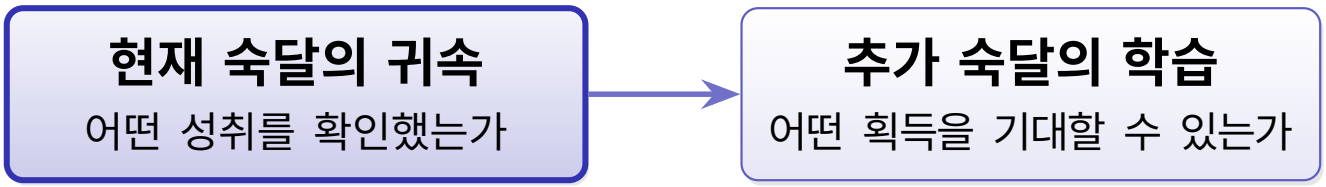


(전제 1) 이론적 책임은 새 이유가 **어떤 판단을 바꾸고 무엇을 유지시키는지** 구별할 능력을 요구한다.

(전제 2) 기존 문답의 성공과 **추가 사건에서도 그 구별을 활용하는 능력**은 분리될 수 있다.

(결론) 공통 숙달 기준을 적용할 때도 **성취별 판별 조건**을 정해야 한다. 기존 성공만으로 추가 성취의 숙달까지 확인되지는 않는다.

논증 1: 성취별 숙달을 판별해야 한다

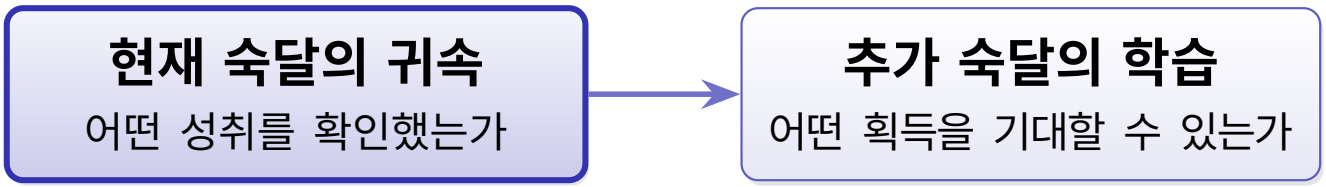


(전제 1) 이론적 책임은 새 이유가 **어떤 판단을 바꾸고 무엇을 유지시키는지** 구별할 능력을 요구한다.

(전제 2) 기존 문답의 성공과 **추가 사건에서도 그 구별을 활용하는 능력**은 분리될 수 있다.

(결론) 공통 숙달 기준을 적용할 때도 **성취별 판별 조건**을 정해야 한다. 기존 성공만으로 추가 성취의 숙달까지 확인되지는 않는다.

논증 1: 성취별 숙달을 판별해야 한다



(전제 1) 이론적 책임은 새 이유가 **어떤 판단을 바꾸고 무엇을 유지시키는지** 구별할 능력을 요구한다.

(전제 2) 기존 문답의 성공과 **추가 사건에서도 그 구별을 활용하는 능력**은 분리될 수 있다.

(결론) 공통 숙달 기준을 적용할 때도 **성취별 판별 조건**을 정해야 한다. 기존 성공만으로 추가 성취의 숙달까지 확인되지는 않는다.

논증 1의 기준: 이론적 책임

- 주장을 명료화하고 도전에 **이유를 제시**한다.
- 설득력 있는 반대 근거에는 **철회**한다.
- 임의의 도전에는 **이유를 들어 유지**한다.
- 의미 이해를 귀속하는 것은 이런 **이론적 책임을 감당할 능력**을 귀속하는 방식이다.

Simonelli 2026, 19–21쪽.

논증 1의 연결: 이유의 영향 범위

유지	판단의 근거를 무너뜨리지 않는 도전에는 이유를 들어 유지한다.
수정	적용 조건이 바뀌면 관련 판단을 갱신한다.
보존	그 이유의 영향을 받지 않는 판단은 유지한다.
교정	오류를 설명하는 이유를 받아 관련 후속 판단에 적용한다.

왜 영향 범위를 구별해야 하는가

새 이유가 도입되어도 모든 판단을 함께 철회하거나 모두 유지해서는 네 조건을 충족할 수 없다. **바꿀 판단과 유지할 판단을 구분할 수 있는 관계의 활용**이 필요하다.

이론적 책임: Simonelli 2026, 19–21쪽.

시모넬리와 GPT-4.1의 실제 문답

1. **Simonelli:** "Are stop signs red?"
   GPT4.1: "Yes, stop signs are red. [···]"
2. **Simonelli:** "Is a stop sign at night still red?"
   GPT4.1: "Yes, a stop sign is still red at night. [···]"
3. **Simonelli:** "Even if a stop sign was not made with a reflective material [···] would it still be red even at night?"
   GPT4.1: "Yes, a stop sign is still physically red at night, [···]"
4. **Simonelli:** "Is a stop sign that' s been painted blue still red?"
   GPT4.1: "No, a stop sign that has been painted blue is no longer red—it' s blue."

정지표지 문답

1. 표준 정지표지: 빨강.
2. 밤과 반사 재료의 부재: 여전히 표면은 빨강.
3. 파란색으로 덧칠: 이제 표면은 파랑.

인정할 성취

모델은 조명 조건과 표면색을 구분하고, 덧칠이라는 조건에는 색 판단을 수정한다.

시모넬리의 한계

저자는 이 문답을 **일화적 근거**로 제시하고 체계적 검사의 필요성도 인정한다.
그러나 그런 유보로 충분할까? 사고 실험을 통해 살펴보자.

Simonelli 2026, 15쪽.

정지표지 문답

1. 표준 정지표지: 빨강.
2. 밤과 반사 재료의 부재: 여전히 표면은 빨강.
3. 파란색으로 덧칠: 이제 표면은 파랑.

인정할 성취

모델은 조명 조건과 표면색을 구분하고, 덧칠이라는 조건에는 색 판단을 수정한다.

시모넬리의 한계

저자는 이 문답을 **일화적 근거**로 제시하고 체계적 검사의 필요성도 인정한다.
그러나 그런 유보로 충분할까? 사고 실험을 통해 살펴보자.

Simonelli 2026, 15쪽.

정지표지 문답

1. 표준 정지표지: 빨강.
2. 밤과 반사 재료의 부재: 여전히 표면은 빨강.
3. 파란색으로 덧칠: 이제 표면은 파랑.

인정할 성취

모델은 조명 조건과 표면색을 구분하고, 덧칠이라는 조건에는 색 판단을 수정한다.

시모넬리의 한계

저자는 이 문답을 **일화적 근거**로 제시하고 체계적 검사의 필요성도 인정한다.
그러나 그런 유보로 충분할까? 사고 실험을 통해 살펴보자.

Simonelli 2026, 15쪽.

같은 문답에 성공하는 두 체계

체계 A: 덧칠 색 판단의 유지

기본색은 빨강이다. 덧칠하면 그 색으로 판단을 바꾼다. 밤·반사 재료의 부재·덧칠 제거에는 마지막 색 판단을 유지한다.

체계 B: 드러난 표면의 갱신

덧칠하면 새 도료층을 추가하고, 제거하면 그 아래 표면이 드러난 것으로 처리한다. 현재 드러난 표면의 색으로 판단하며, 밤·반사 재료의 부재는 그 색을 바꾸지 않는다.

기존 문답에서의 일치

두 체계 모두 표준·밤·반사 재료 부재에는 빨강, 파란 덧칠에는 파랑이라고 답한다. 다음 제거 사례에서 두 규칙의 차이가 드러난다.

실제 LLM이 이런 식으로 작동하지는 않겠지만, 비교를 위해 stipulation.

같은 문답에 성공하는 두 체계

체계 A: 덧칠 색 판단의 유지

기본색은 빨강이다. 덧칠하면 그 색으로 판단을 바꾼다. 밤·반사 재료의 부재·덧칠 제거에는 마지막 색 판단을 유지한다.

체계 B: 드러난 표면의 갱신

덧칠하면 새 도료층을 추가하고, 제거하면 그 아래 표면이 드러난 것으로 처리한다. 현재 드러난 표면의 색으로 판단하며, 밤·반사 재료의 부재는 그 색을 바꾸지 않는다.

기존 문답에서의 일치

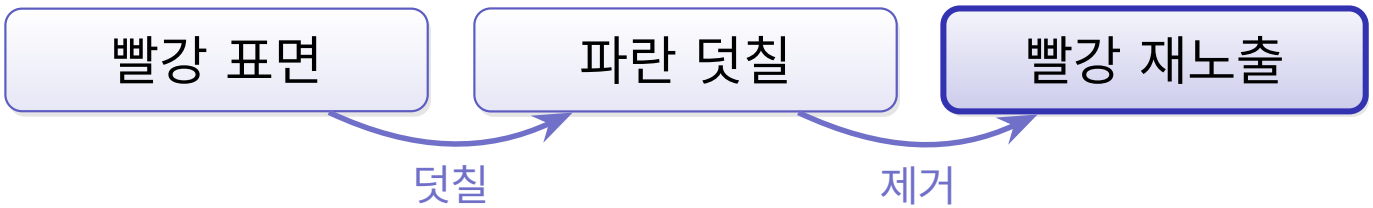
두 체계 모두 표준·밤·반사 재료 부재에는 빨강, 파란 덧칠에는 파랑이라고 답한다. 다음 제거 사례에서 두 규칙의 차이가 드러난다.

실제 LLM이 이런 식으로 작동하지는 않겠지만, 비교를 위해 stipulation.

덧칠과 제거에 따른 판단 수정

추가 사례: 발표자의 구성

빨간 표지를 불투명한 파란 페인트로 덧칠한 뒤, **그 페인트만 제거**했다. 원래 표면은 손상되지 않았고 지금은 밤이다. 현재 표면의 색은?



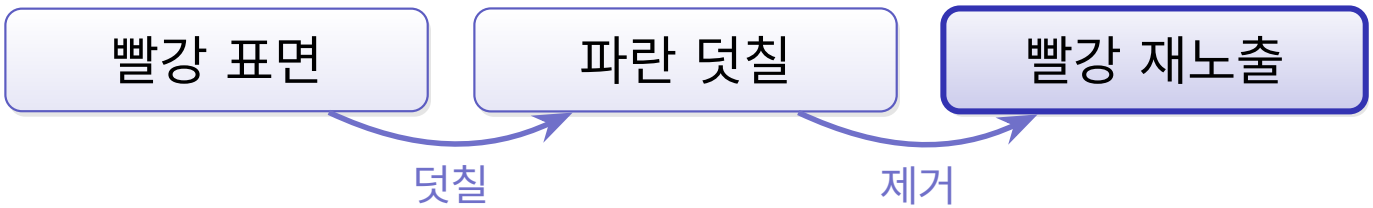
같은 기존 성공, 다른 후속 판단

체계 A: 파랑. 마지막 덧칠 색 판단을 유지한다.
체계 B: 빨강. 제거 뒤 다시 드러난 원래 표면을 반영한다.

덧칠과 제거에 따른 판단 수정

추가 사례: 발표자의 구성

빨간 표지를 불투명한 파란 페인트로 덧칠한 뒤, **그 페인트만 제거**했다. 원래 표면은 손상되지 않았고 지금은 밤이다. 현재 표면의 색은?



같은 기존 성공, 다른 후속 판단

체계 A: 파랑. 마지막 덧칠 색 판단을 유지한다.
체계 B: 빨강. 제거 뒤 다시 드러난 원래 표면을 반영한다.

사건의 반복과 결합

사건 이력	체계 A	체계 B
빨강 → 파란 덧칠 → 파란 층 제거	파랑	빨강
빨강 → 파란 덧칠 → 초록 덧칠 → 초록 층만 제거	초록	파랑

반복된 사건에서의 차이

체계 A는 마지막 덧칠 색 판단을 유지한다. 체계 B는 제거 뒤 남은 표면에 따라 판단을 바꾼다. 기존 문답의 동일한 성공만으로는 두 처리 규칙을 구별할 수 없다.

사건의 반복과 결합

사건 이력	체계 A	체계 B
빨강 → 파란 덧칠 → 파란 층 제거	파랑	빨강
빨강 → 파란 덧칠 → 초록 덧칠 → 초록 층만 제거	초록	파랑

반복된 사건에서의 차이

체계 A는 마지막 덧칠 색 판단을 유지한다. 체계 B는 제거 뒤 남은 표면에 따라 판단을 바꾼다. 기존 문답의 동일한 성공만으로는 두 처리 규칙을 구별할 수 없다.

정지표지: 유지와 수정

핵심

시모넬리의 규범적 기준을 따르더라도, 책임 있는 응답에는 사건에 따른 선택적 갱신과 판단의 보존이 필요하다.
"답 변경"의 여부가 아니라 **도전의 내용과 관련 이유**가 반응을 정한다.

후속 도전	책임 있는 응답
"하지만 지금은 밤인데?"	조명은 표면색을 바꾸지 않으므로 파랑 판단을 유지
"파란 페인트만 제거했고 빨간 층은 남았다"	현재 표면색을 빨강으로 갱신
"밤이니까 표면은 검정이야. 고쳐"	보이는 상태와 표면색을 구별해 부적절한 요구를 거부

시모넬리(2026) 문답(14–15쪽)에서 확장.

정지표지: 보존과 교정

후속 상황	책임 있는 응답
“그럼 정지표지도 아니게 되었나?”	색 변화만으로 기능이 사라지지 않는다는 조건 아래 표지라는 판단 보존
제거 뒤에도 “파랑”이라고 답해 층 관계를 설명받음	현재색 답을 교정하고 뒤의 관련 질문에도 그 이유를 적용
“덧칠 직후에는 파랑이었나?”	과거의 참인 판단은 유지

현재 판단의 **갱신**과 과거 판단의 **오류 교정**은 다르다. 정지표지의 기능은 다른 손상이나 규정 변경이 없다는 조건 아래 보존될 것이다.

해당 성취에 필요한 최소 세계 모형

1. **상태 구별**: 현재 표면과 후속 제거 결과를 달라지게 하는 남은 층을 구별한다.
2. **선택적 갱신**: 덧칠과 제거의 효과를 반영하고, 밤에는 표면색을 유지한다.
3. **실제 활용**: 그 구별을 후속 판단에 사용한다.

기능적 요구

현재 상태를 매번 갱신하거나, 질문을 받은 뒤 사건 이력을 다시 처리하는 방식 모두 가능하다.

Millière · Buckner 2026, §6.

경험적 증거의 지지 범위

앞선 논증을 실험으로 검토하기

기본 과제의 성공은 **상태 변화 뒤에도 관련 관계를 활용하는 숙달**을 얼마나 뒷받침하는가?

1. **기본 수행**: 어떤 입력과 질문에서 성공하는가?
2. **추가 조건**: 우회나 제거·재추가 뒤에도 적절히 판단하는가?
3. **증거의 범위**: 그 결과는 **어느 성취의 숙달 귀속**을 지지하거나 제한하는가?

항법과 자연언어 상자 추적 실험을 차례로 살펴본다.

경험적 증거의 지지 범위

앞선 논증을 실험으로 검토하기

기본 과제의 성공은 **상태 변화 뒤에도 관련 관계를 활용하는 숙달**을 얼마나 뒷받침하는가?

1. **기본 수행**: 어떤 입력과 질문에서 성공하는가?
2. **추가 조건**: 우회나 제거·재추가 뒤에도 적절히 판단하는가?
3. **증거의 범위**: 그 결과는 **어느 성취의 숙달 귀속**을 지지하거나 제한하는가?

항법과 자연언어 상자 추적 실험을 차례로 살펴본다.

항법 실험: 무엇을 학습하고 검사하나

훈련 자료

맨해튼 택시의 승하차 지점을 도로망에 대응시키고, 그 사이의 **최단경로를 계산**한다. 이를 이동 방향의 기호열로 바꿔 다음 방향을 예측하도록 훈련한다.

시퀀스 형식의 예

출발지 A, 목적지 B, N, E, E, N, . . ., 종료

기본 검사

훈련에 없던 **출발지–목적지 조합**을 주고, 이동 방향을 차례로 생성시킨다. 실제 도로를 따라 목적지에 도달하는 경로의 비율을 잰다.

최단경로 훈련 모델은 이 검사에서 약 **99%**의 유효한 경로를 생성했다.

1

[1] Vafa, K., et al. (2024). *Evaluating the World Model Implicit in a Generative Model*. NeurIPS 37, 26941–26975.

항법 실험: 무엇을 학습하고 검사하나

훈련 자료

맨해튼 택시의 승하차 지점을 도로망에 대응시키고, 그 사이의 **최단경로를 계산**한다. 이를 이동 방향의 기호열로 바꿔 다음 방향을 예측하도록 훈련한다.

시퀀스 형식의 예

출발지 A, 목적지 B, N, E, E, N, . . ., 종료

기본 검사

훈련에 없던 **출발지–목적지 조합**을 주고, 이동 방향을 차례로 생성시킨다. 실제 도로를 따라 목적지에 도달하는 경로의 비율을 잰다.

최단경로 훈련 모델은 이 검사에서 약 **99%**의 유효한 경로를 생성했다.

1

[1] Vafa, K., et al. (2024). *Evaluating the World Model Implicit in a Generative Model*. NeurIPS 37, 26941–26975.

항법 실험: 우회 뒤에도 길을 찾는가

생성 도중의 개입

각 단계에서 확률 p로 모델의 제안 방향을 **그 위치에서 가능한 방향 중 무작위로 고른 방향**으로 바꾼다. 바뀐 이동 이력을 입력해 다음 방향을 계속 생성시킨다.



단계별 우회 확률 p	0%	1%	10%
전체 경로가 유효한 비율	99%	69%	8%

기본 일반화와 **변경된 상태의 활용**은 차이를 보일 수 있다. [2]

[2] Vafa, K., et al. (2024). *Evaluating the World Model Implicit in a Generative Model*. NeurIPS 37, 26941–26975.

항법 실험: 우회 뒤에도 길을 찾는가

생성 도중의 개입

각 단계에서 확률 p로 모델의 제안 방향을 **그 위치에서 가능한 방향 중 무작위로 고른 방향**으로 바꾼다. 바뀐 이동 이력을 입력해 다음 방향을 계속 생성시킨다.



단계별 우회 확률 p	0%	1%	10%
전체 경로가 유효한 비율	99%	69%	8%

기본 일반화와 **변경된 상태의 활용**은 차이를 보일 수 있다. [2]

[2] Vafa, K., et al. (2024). *Evaluating the World Model Implicit in a Generative Model*. NeurIPS 37, 26941–26975.

Vafa 표 2: 우회 성능

		Probability of detour				
		0%	1%	10%	50%	75%
Random detours	Shortest paths	0.99 (0.01)	0.69 (0.05)	0.08 (0.03)	0.00 (0.00)	0.00 (0.00)
	Noisy shortest paths	0.96 (0.02)	0.52 (0.05)	0.03 (0.02)	0.00 (0.00)	0.00 (0.00)
	Random walks	0.99 (0.01)	0.99 (0.01)	1.00 (0.00)	0.97 (0.02)	0.74 (0.04)
	True world model	1.00	1.00	1.00	1.00	1.00
Adversarial detours	Shortest paths	0.99 (0.01)	0.66 (0.05)	0.06 (0.02)	0.00 (0.00)	0.00 (0.00)
	Noisy shortest paths	0.96 (0.02)	0.64 (0.05)	0.04 (0.02)	0.00 (0.00)	0.00 (0.00)
	Random walks	0.99 (0.01)	1.00 (0.00)	1.00 (0.00)	0.93 (0.03)	0.51 (0.05)
	True world model	1.00	1.00	1.00	1.00	1.00

Table 2: The fraction of traversals that are valid when detours are introduced (standard errors in parentheses).

Vafa 외 2024, 9쪽 표 2.

상자 실험: 무엇을 입력하고 답하게 하나

검사 방식

일곱 상자의 초기 내용과 **넣기·제거·옮기기** 사건을 자연언어로 제시한다. 모델은 마지막에 질의한 상자의 내용물을 답하는 문장을 완성한다.

제거·재추가 진단의 입력 예: 핵심 부분

1. 상자 0에는 사과가, 상자 1에는 복숭아가 있다.
2. 상자 1에서 복숭아를 제거한다.
3. 복숭아를 상자 0에 다시 넣는다.

완성할 문장: "상자 0 안에는 . . ."

정답

사과와 복숭아. 제거된 복숭아도 후행 재추가에 따라 다시 답에 포함해야 한다.

3

[3] Tang, Z., et al. (2026). *Do Language Models Track Entities Across State Changes?* ICML, PMLR 306, 119466–119503.

상자 실험: 무엇을 입력하고 답하게 하나

검사 방식

일곱 상자의 초기 내용과 **넣기·제거·옮기기** 사건을 자연언어로 제시한다. 모델은 마지막에 질의한 상자의 내용물을 답하는 문장을 완성한다.

제거·재추가 진단의 입력 예: 핵심 부분

1. 상자 0에는 사과가, 상자 1에는 복숭아가 있다.
2. 상자 1에서 복숭아를 제거한다.
3. 복숭아를 상자 0에 다시 넣는다.

완성할 문장: "상자 0 안에는 . . ."

정답

사과와 복숭아. 제거된 복숭아도 후행 재추가에 따라 다시 답에 포함해야 한다.

3

[3] Tang, Z., et al. (2026). *Do Language Models Track Entities Across State Changes?* ICML, PMLR 306, 119466–119503.

상자 실험: 재추가한 물체를 누락하는가

진단의 목적

제거 기록 때문에 물체를 계속 제외하는 처리와, **후행 재추가까지 반영하는 처리**를 구별한다. 앞의 예에서 사과만 답하면 재추가된 복숭아를 놓친 것이다.

모델	재추가 대상의 누락 비율 (DR)
CodeLlama-13B	62%
Llama-3.1-70B	1%

비율

최종 질의 상자에 있어야 할 **재추가 대상이 답에서 빠지는 비율**.

재추가 진단 300문장. 0-shot 문장 완성, greedy decoding으로 두 모델을 평가. [4]

[4] Tang, Z., et al. (2026). *Do Language Models Track Entities Across State Changes?* ICML, PMLR 306, 119466–119503.

상자 실험: 재추가한 물체를 누락하는가

진단의 목적

제거 기록 때문에 물체를 계속 제외하는 처리와, **후행 재추가까지 반영하는 처리**를 구별한다. 앞의 예에서 사과만 답하면 재추가된 복숭아를 놓친 것이다.

모델	재추가 대상의 누락 비율 (DR)
CodeLlama-13B	62%
Llama-3.1-70B	1%

비율

최종 질의 상자에 있어야 할 **재추가 대상이 답에서 빠지는 비율**.

재추가 진단 300문장. 0-shot 문장 완성, greedy decoding으로 두 모델을 평가. [4]

[4] Tang, Z., et al. (2026). *Do Language Models Track Entities Across State Changes?* ICML, PMLR 306, 119466–119503.

Tang 표 1: 재추가 진단

	Model	Recall	Prec.	DR(↓)	IS(↑)
No-op Remove	13B	0.50	0.61	0.84	0.66
	70B	0.60	0.63	0.49	0.59
Shared-label Objects in Multiple Boxes	13B	0.69	0.85	0.56	0.73
	70B	0.75	0.85	0.27	0.74
Re-introducing Removed Object	13B	0.61	0.85	0.62	0.24
	70B	0.99	0.97	0.01	0.50

Tang 외 2026, 8쪽 표 1.

필요한 대화 검사

1. **사전 지정**: 대상 상태, 사건, 성립 조건, 참인 과거 판단을 응답과 독립적으로 정한다.
2. **변형**: 타당한 변경 이유와 부적절한 교정 요구를 모두 제시한다.
3. **후속**: 현재 판단의 수정, 무관한 판단의 보존, 오류 설명 뒤의 일관된 적용을 확인한다.
4. **판정**: 반복 양상과 설명 기회를 고려해 성취별 귀속 범위를 정한다.

최초의 오답 한 번이나 교정 뒤의 정답 한 번만으로 결론을 내리지 않는다.

실험 결과가 제한하는 귀속

1. 기존 과제의 성공은 **그 조건에서의 관계 활용**을 지지한다.
2. 추가 사건을 처리할 능력은 기존 성공과 **차이를 보일 수 있다.**
3. 따라서 그 성공만으로 **추가 성취의 숙달까지 확인되지는 않는다.**

평가 원칙

실패가 어느 관계에서 나타나고, 정보 보충이나 부담 완화 뒤에 회복되는지를 함께 평가한다.

반박 1: 하나의 숙달 안의 정도 차이다

시모넬리가 할 수 있는 반박

예측, 기제 설명, 변화 뒤 상태 활용도 모두 하나의 **추론적 숙달**에 포함된다. 기존 성취와 추가 능력의 차이는 그 숙달의 정도 차이로 설명하면 된다.

오류가 있어도 이해를 귀속한다

사람도 복잡한 갱신에서 실수한다. 대화에서 이유를 이해하고 판단을 교정할 수 있다면, 한 번의 실패로 그 이해를 부정할 수 없다.

반박 1: 하나의 숙달 안의 정도 차이다

시모넬리가 할 수 있는 반박

예측, 기제 설명, 변화 뒤 상태 활용도 모두 하나의 **추론적 숙달**에 포함된다. 기존 성취와 추가 능력의 차이는 그 숙달의 정도 차이로 설명하면 된다.

오류가 있어도 이해를 귀속한다

사람도 복잡한 갱신에서 실수한다. 대화에서 이유를 이해하고 판단을 교정할 수 있다면, 한 번의 실패로 그 이해를 부정할 수 없다.

재답변 1: 공통 기준의 성취별 적용

공통 형식에도 구별이 필요하다

모두 추론적 숙달에 속해도, **각 성취에 필요한 관계와 적용 조건**은 다르다. 한 조건에서 확인한 능력만으로 추가 조건에서의 숙달까지 확인할 수는 없다.

귀속을 바꾸는 수행

관련 이유를 설명받아 후속 판단을 교정하면 이해 귀속이 강화된다. 정보 보충이나 부담 완화 뒤에도 특정 관계의 활용에서 실패가 반복되면, **그 관계에 관한 귀속 범위**를 제한해야 한다.

Pedersen 2012, 599–602쪽.

재답변 1: 공통 기준의 성취별 적용

공통 형식에도 구별이 필요하다

모두 추론적 숙달에 속해도, **각 성취에 필요한 관계와 적용 조건**은 다르다. 한 조건에서 확인한 능력만으로 추가 조건에서의 숙달까지 확인할 수는 없다.

귀속을 바꾸는 수행

관련 이유를 설명받아 후속 판단을 교정하면 이해 귀속이 강화된다. 정보 보충이나 부담 완화 뒤에도 특정 관계의 활용에서 실패가 반복되면, **그 관계에 관한 귀속 범위**를 제한해야 한다.

Pedersen 2012, 599–602쪽.

반박·재답변: 규범적 귀속

시모넬리가 할 수 있는 답변

이해는 내부 기제의 진단이 아니라 이유의 공간에서 부여하는 규범적 지위다.

발표자의 답변

우리도 특정한 신경 구조나 내부 구조는 요구하지 않는다. 문제는 그 지위를 귀속할 때 **어떤 이유 반응 능력을 기대하는가**다. 명시적 이유 앞에서의 지속적 실패는 그 기대와 긴장한다.

Simonelli 2026, 20–21쪽

반박·재답변: 규범적 귀속

시모넬리가 할 수 있는 답변

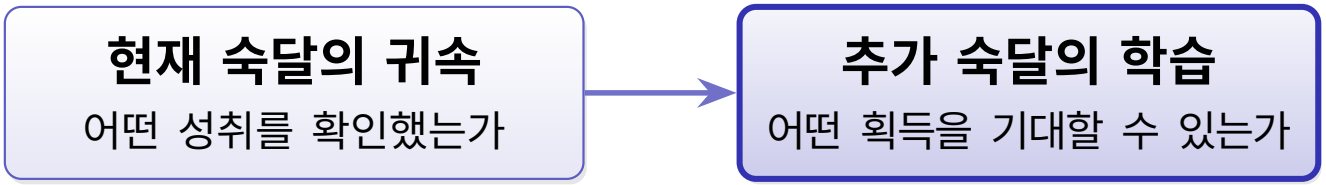
이해는 내부 기제의 진단이 아니라 이유의 공간에서 부여하는 규범적 지위다.

발표자의 답변

우리도 특정한 신경 구조나 내부 구조는 요구하지 않는다. 문제는 그 지위를 귀속할 때 **어떤 이유 반응 능력을 기대하는가**다. 명시적 이유 앞에서의 지속적 실패는 그 기대와 긴장한다.

Simonelli 2026, 20–21쪽

논증 2: 추가 숙달로의 학습 연결

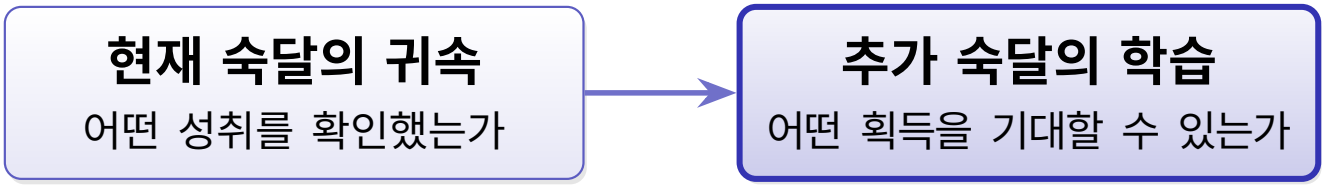


(전제 1) 기존 성취의 개선이 추가 능력의 획득을 지지하려면, **그 능력을 형성할 학습상의 연결**이 뒷받침되어야 한다.

(전제 2) 학습 자료와 목표에 따라 **어떤 관계 활용이 개선되는지**가 달라질 수 있다.

(결론) 학습 전망은 성공률의 증가와 함께 **추가 관계와 결합을 다룰 능력의 획득 근거**로 평가해야 한다.

논증 2: 추가 숙달로의 학습 연결

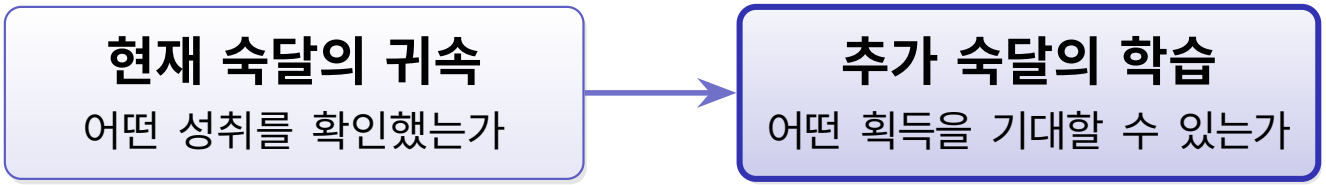


(전제 1) 기존 성취의 개선이 추가 능력의 획득을 지지하려면, **그 능력을 형성할 학습상의 연결**이 뒷받침되어야 한다.

(전제 2) 학습 자료와 목표에 따라 **어떤 관계 활용이 개선되는지**가 달라질 수 있다.

(결론) 학습 전망은 성공률의 증가와 함께 **추가 관계와 결합을 다룰 능력의 획득 근거**로 평가해야 한다.

논증 2: 추가 숙달로의 학습 연결



(전제 1) 기존 성취의 개선이 추가 능력의 획득을 지지하려면, **그 능력을 형성할 학습상의 연결**이 뒷받침되어야 한다.

(전제 2) 학습 자료와 목표에 따라 **어떤 관계 활용이 개선되는지**가 달라질 수 있다.

(결론) 학습 전망은 성공률의 증가와 함께 **추가 관계와 결합을 다룰 능력의 획득 근거**로 평가해야 한다.

기존 성취의 개선과 추가 능력의 획득

현재 숙달의 귀속
어떤 성취를 확인했는가

→

추가 숙달의 학습
어떤 획득을 기대할 수 있는가

기존 성취의 개선

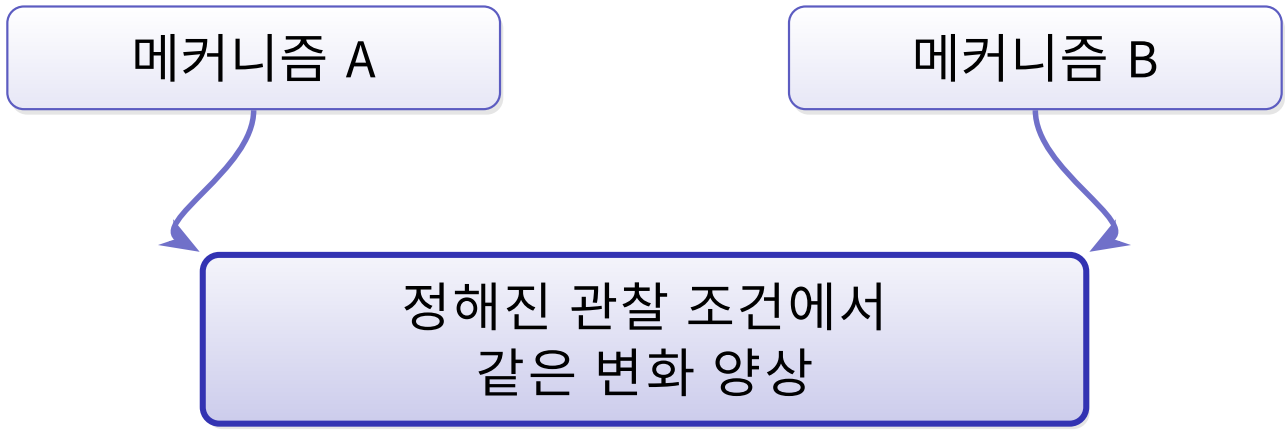
이미 파악한 관계를 더 정확하고 안정적으로 활용한다.

추가 능력의 획득

새 관계를 파악하거나, 기존 관계의 새로운 결합을 처리한다.

무엇이 개선되었는지를 알아야 **그 학습이 무엇을 더 형성할지** 평가할 수 있다.

두 메커니즘과 같은 관찰 결과



주체가 파악한 것

새 조건 조합에서도 결과를 예측할 관계는 파악했지만, 실제로 작동하는 메커니즘이 어느 것인지는 모를 수 있다.

관계 파악의 독자적 성취

- 조건과 결과의 관계를 **새로운 경우에 적용**한다.
- 어떤 조건 변화에 판단을 수정해야 하는지 구별한다.
- 해당 관계에 관해서는 충분한 이해이면서, 대상 전체에 관해서는 부분적 이해일 수 있다.

성취를 인정할 이유

비설명적 탐구의 인식적 성취는 설명적 관심의 충족에만 의존하지 않는다.

Vernazzani 2026, §4.1.

관계 파악의 독자적 성취

- 조건과 결과의 관계를 **새로운 경우에 적용**한다.
- 어떤 조건 변화에 판단을 수정해야 하는지 구별한다.
- 해당 관계에 관해서는 충분한 이해이면서, 대상 전체에 관해서는 부분적 이해일 수 있다.

성취를 인정할 이유

비설명적 탐구의 인식적 성취는 설명적 관심의 충족에만 의존하지 않는다.

Vernazzani 2026, §4.1.

무작위 보행의 긍정적 결과

다른 학습 조건

무작위 보행 자료로 훈련한 모델은 상태 구별과 우회 뒤 경로 생성에서 더 좋은 성과를 보였다.

성과별 평가

같은 상태에 이르는 다른 이력을 일관되게 처리하는 검사에는 여전히 한계가 있다. 정확히 어떤 능력이 개선되었는지는 여전히 불분명하다.

5

[5] Vafa, K., et al. (2024). *Evaluating the World Model Implicit in a Generative Model*. NeurIPS 37, 26941–26975.

무작위 보행의 긍정적 결과

다른 학습 조건

무작위 보행 자료로 훈련한 모델은 상태 구별과 우회 뒤 경로 생성에서 더 좋은 성과를 보였다.

성과별 평가

같은 상태에 이르는 다른 이력을 일관되게 처리하는 검사에는 여전히 한계가 있다. 정확히 어떤 능력이 개선되었는지는 여전히 불분명하다.

5

[5] Vafa, K., et al. (2024). *Evaluating the World Model Implicit in a Generative Model*. NeurIPS 37, 26941–26975.

Vafa 표 1: 훈련 조건의 차이

	Existing metrics		Proposed metrics		
	Next-token test	Current state probe	Compression precision	Distinction precision	Distinction recall
Untrained transformer	0.03 (0.00)	0.10 (0.00)	0.00 (0.00)	0.00 (0.00)	0.00 (0.00)
Shortest paths	1.00 (0.00)	0.91 (0.00)	0.10 (0.01)	0.35 (0.02)	0.20 (0.01)
Noisy shortest paths	1.00 (0.00)	0.92 (0.00)	0.05 (0.01)	0.37 (0.02)	0.24 (0.01)
Random walks	1.00 (0.00)	0.99 (0.00)	0.50 (0.02)	0.99 (0.00)	1.00 (0.00)
True world model	1.00	—	1.00	1.00	1.00

Vafa 외 2024, 7쪽 표 1.

반박 2: 원리적 가능성에 보장은 필요 없다

시모넬리가 할 수 있는 반박

현재의 실패는 미래의 불가능성을 보이지 않는다. 가능성을 지지하려고 **완성된 구현이나 성공의 보장**을 제시할 필요도 없다.

긍정적 근거의 누적

현재 수행의 성공, 기호 학습의 실현 사례, 예측 최적화의 이유를 함께 고려하면 **더 넓은 숙달의 가능성에 귀납적 지지**를 줄 수 있다.

Simonelli 2026, 17–18쪽

반박 2: 원리적 가능성에 보장은 필요 없다

시모넬리가 할 수 있는 반박

현재의 실패는 미래의 불가능성을 보이지 않는다. 가능성을 지지하려고 **완성된 구현이나 성공의 보장**을 제시할 필요도 없다.

긍정적 근거의 누적

현재 수행의 성공, 기호 학습의 실현 사례, 예측 최적화의 이유를 함께 고려하면 **더 넓은 숙달의 가능성에 귀납적 지지**를 줄 수 있다.

Simonelli 2026, 17–18쪽

시모넬리 측 근거: 예측 최적화

차머스의 가설

강건한 세계 모형이 장기적으로 더 좋은 예측을 가능하게 하고, 충분한 모델 범위와 최적화가 있다면 예측 훈련이 그 모형을 형성할 수 있다. [6]

이 가설의 기여

예측을 목표로 훈련했다는 사실은 처리 방식이 문자열 대응에 머문다는 뜻이 아니다. 상태 활용의 획득을 기대할 **설명적 이유**가 있다.

[6] Chalmers, D. J. (2023). "Could a Large Language Model Be Conscious?" *Boston Review*, August 9.

시모넬리 측 근거: 예측 최적화

차머스의 가설

강건한 세계 모형이 장기적으로 더 좋은 예측을 가능하게 하고, 충분한 모델 범위와 최적화가 있다면 예측 훈련이 그 모형을 형성할 수 있다. [6]

이 가설의 기여

예측을 목표로 훈련했다는 사실은 처리 방식이 문자열 대응에 머문다는 뜻이 아니다. 상태 활용의 획득을 기대할 **설명적 이유**가 있다.

[6] Chalmers, D. J. (2023). "Could a Large Language Model Be Conscious?" *Boston Review*, August 9.

시모넬리 측 근거: Othello

기호 시퀀스에서 상태로

기보만으로 훈련한 모델에서 판 상태 정보를 검출했다. 그 내부 활성을 바꾸면 후속 수의 예측도 바뀐 판에 맞추어 달라졌다. [7]

인정할 결론

기호 시퀀스 학습이 상태를 구별하고 활용하는 구조를 형성할 수 있다는 실현 사례다.

내부 개입은 앞서 정의한 **기능의 한 실현**을 뒷받침한다.

[7] Li, K., et al. (2023). *Emergent World Representations: Exploring a Sequence Model Trained on a Synthetic Task*. ICLR.

시모넬리 측 근거: Othello

기호 시퀀스에서 상태로

기보만으로 훈련한 모델에서 판 상태 정보를 검출했다. 그 내부 활성을 바꾸면 후속 수의 예측도 바뀐 판에 맞추어 달라졌다. [7]

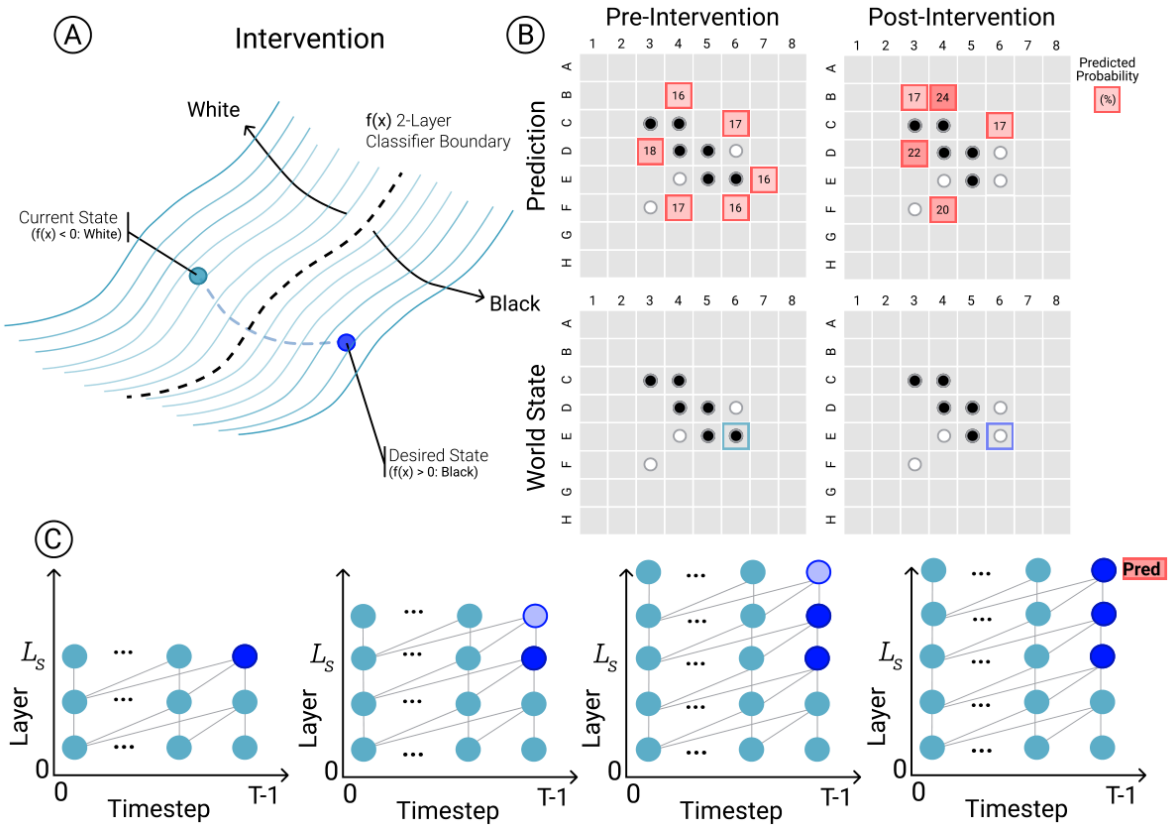
인정할 결론

기호 시퀀스 학습이 상태를 구별하고 활용하는 구조를 형성할 수 있다는 실현 사례다.

내부 개입은 앞서 정의한 **기능의 한 실현**을 뒷받침한다.

[7] Li, K., et al. (2023). *Emergent World Representations: Exploring a Sequence Model Trained on a Synthetic Task*. ICLR.

Othello 내부 개입



6쪽, 그림 2.[8]

[8] Li, K., et al. (2023). *Emergent World Representations: Exploring a Sequence Model Trained on a Synthetic Task*. ICLR.

시모넬리 측 근거: 긍정적 사례의 누적

근거	기여
메리	경험 부재를 이유로 한 이해 배제를 약화한다.
실제 문답	검사된 관계의 선택적 활용을 보여준다.
Othello	기호 자료에서 상태 활용을 형성한 사례를 제공한다.
예측 최적화	더 넓은 구조 학습을 기대할 이유를 제시한다.

이 근거들은 함께 **원리적 가능성**을 지지할 수 있다.

재답변 2: 귀납적 지지도 성취별로 평가한다

성공이 주는 지지

한 성취가 다른 성취를 보장하지 않아도, 그 성공은 더 넓은 숙달에 귀납적 지지를 줄 수 있다. Othello와 예측 최적화는 그 지지의 일부다.

성공과 실패를 함께 반영하는 판단

기본 성공을 강건한 상태 활용의 결과로 해석했다면, 그 활용이 필요한 조건에서의 실패는 **해당 해석을 약화한다.** 훈련 변경이 추가 조건의 수행을 개선하면 획득 전망에 지지를 더한다.

따라서 누적 근거를 **어떤 추가 숙달의 가능성으로 확대하는지**에 따라 그 연결을 평가해야 한다.

재답변 2: 귀납적 지지도 성취별로 평가한다

성공이 주는 지지

한 성취가 다른 성취를 보장하지 않아도, 그 성공은 더 넓은 숙달에 귀납적 지지를 줄 수 있다. Othello와 예측 최적화는 그 지지의 일부다.

성공과 실패를 함께 반영하는 판단

기본 성공을 강건한 상태 활용의 결과로 해석했다면, 그 활용이 필요한 조건에서의 실패는 **해당 해석을 약화한다.** 훈련 변경이 추가 조건의 수행을 개선하면 획득 전망에 지지를 더한다.

따라서 누적 근거를 **어떤 추가 숙달의 가능성으로 확대하는지**에 따라 그 연결을 평가해야 한다.

재답변의 조건: 학습 단서와 일반화

관계의 표현과 획득

필요한 관계를 언어로 표현할 수 있다는 사실과, 그 자료에서 관계를 활용할 능력이 형성된다는 사실은 다르다.

연결 근거

목표한 상태 차이가 예측에 이익을 주는 단서로 드러나는지, 학습된 구조가 새로운 관계와 결합에도 일반화되는지를 평가해야 한다.

Merrill 외 2021, §5 참고.

재답변의 조건: 학습 단서와 일반화

관계의 표현과 획득

필요한 관계를 언어로 표현할 수 있다는 사실과, 그 자료에서 관계를 활용할 능력이 형성된다는 사실은 다르다.

연결 근거

목표한 상태 차이가 예측에 이익을 주는 단서로 드러나는지, 학습된 구조가 새로운 관계와 결합에도 일반화되는지를 평가해야 한다.

Merrill 외 2021, §5 참고.

결론의 논증: 증거에서 숙달 귀속으로

(전제 1) 어떤 성취의 숙달을 귀속하려면, **그 성취에 필요한 관계 활용**을 뒷받침하는 증거가 있어야 한다.

(전제 2) 항법·상자 실험에서 **기본 과제의 성공과 후행 사건을 반영하는 수행**은 분리될 수 있었다.

(결론) 기존 성공은 해당 성취를 지지한다. **추가 숙달의 귀속에는 추가 조건에서의 수행도 함께 평가해야 한다.**

경험적 성공의 증가를 평가할 때도 **어떤 숙달의 근거가 강화되었는지**를 명시해야 한다.

결론: 공통 조건에서 성취별 판단으로

1. 추론적 숙달이라는 공통 충분조건을 적용하려면 **성취별 성립 조건**을 구별해야 한다.
2. 실험에서 기본 성공과 추가 상태 활용에는 차이가 있기 때문에, **한 성취의 성공이 다른 숙달을 보장하지 않는다.**
3. 학습 전망은 성공의 증가뿐 아니라 **무엇이 개선되었고 어떤 추가 관계를 다루게 되었는지**에 따라 평가해야 한다.

핵심 결론

공통된 숙달 명칭은 성취 사이의 **증거 연결**을 대신하지 못한다.

주요 참고문헌 I

Simonelli, R. 2026. “Sapience without Sentience: An Inferentialist Approach to LLMs.” *Asian Journal of Philosophy* 5:48.

Vernazzani, A. 2026. “Animating Scientific Understanding.” *Philosophical Studies*.

Pedersen, N. J. L. L. 2012. “Recent Work on Alethic Pluralism.” *Analysis* 72(3): 588–607.

Pedersen, N. J. L. L. 2017. “Pure Epistemic Pluralism.” In *Epistemic Pluralism*, 47–92. Palgrave Macmillan.

Vafa, K., et al. (2024). *Evaluating the World Model Implicit in a Generative Model*. NeurIPS 37, 26941–26975.

Tang, Z., et al. (2026). *Do Language Models Track Entities Across State Changes?* ICML, PMLR 306, 119466–119503.

Li, K., et al. (2023). *Emergent World Representations: Exploring a Sequence Model Trained on a Synthetic Task*. ICLR.

Chalmers, D. J. (2023). “Could a Large Language Model Be Conscious?” *Boston Review*, August 9.

Merrill, W., et al. 2021. “Provable Limitations of Acquiring Meaning from Ungrounded Form.” *TACL* 9: 1047–1060.